L'impact des probabilités dans l'amélioration des modèles prédictifs

Abderrahman EL OUALI
Ingénierie des Données & Recherche Appliquée

20 avril 2026

Résumé

Dans beaucoup de projets en Data Science, on a tendance à voir les algorithmes comme de simples outils d'optimisation. Pourtant, en pratique, ce qui fait réellement la différence dans la qualité d'un modèle, c'est sa capacité à gérer l'incertitude. Dans cet article, je propose de revenir sur le rôle central des probabilités dans la construction de modèles prédictifs fiables. Nous verrons notamment comment des concepts comme le Maximum de Vraisemblance ou l'Inférence Bayésienne permettent non seulement d'améliorer les performances, mais aussi de rendre les modèles plus robustes face à des données imparfaites.

1 Introduction

Quand on débute en machine learning, on cherche souvent à minimiser une erreur : écart quadratique, log-loss, etc. C'est une approche efficace, mais elle reste incomplète. Dans le monde réel, les données ne sont jamais propres : elles sont bruitées, parfois biaisées, et souvent incomplètes.

C'est là que les probabilités deviennent essentielles. Au lieu de demander au modèle une réponse unique, on lui demande d'exprimer un niveau de confiance. Par exemple, au lieu d'annoncer " la valeur sera 10 ", un modèle probabiliste dira plutôt " il y a de fortes chances que la valeur se situe entre 8 et 12 ".

Ce changement de perspective peut paraître subtil, mais il change profondément la manière dont on exploite les modèles en production.

2 Estimation par Maximum de Vraisemblance (MLE)

Un des premiers outils probabilistes que l'on rencontre est le Maximum de Vraisemblance. L'idée, au fond, est assez intuitive : on cherche les paramètres du modèle qui expliquent le mieux les données observées.

Si l'on considère un ensemble de données $D = \{x_1, x_2, \ldots, x_n\}$ supposées indépendantes, et un modèle paramétré par θ, on définit la vraisemblance par :

$$L(\theta) = \prod_{i=1}^{n} P(x_i|\theta)$$

En pratique, travailler directement avec ce produit n'est pas très stable numériquement. On préfère donc utiliser la log-vraisemblance :

$$\mathcal{L}(\theta) = \sum_{i=1}^{n} \log P(x_i|\theta)$$

L'objectif devient alors de trouver :

$$\hat{\theta} = \arg\max_{\theta} \mathcal{L}(\theta)$$

Même si cela peut sembler théorique, c'est exactement ce qui se cache derrière beaucoup d'algorithmes utilisés au quotidien, comme la régression logistique ou même certains modèles de réseaux de neurones.

3 Inférence bayésienne : aller au-delà des données

Le Maximum de Vraisemblance fonctionne bien quand on a beaucoup de données. Mais dans des contextes réels, ce n'est pas toujours le cas. Et parfois, on dispose déjà d'une certaine expertise métier qu'on aimerait intégrer dans le modèle.

C'est précisément ce que permet l'approche bayésienne.

Le théorème de Bayes s'écrit :

$$P(\theta|D) = \frac{P(D|\theta)P(\theta)}{P(D)}$$

On peut l'interpréter assez simplement :

— $P(\theta|D)$ correspond à ce que l'on croit après avoir vu les données,
— $P(\theta)$ représente ce que l'on pensait avant (notre intuition ou expertise),
— et $P(D|\theta)$ mesure à quel point le modèle explique bien les données.

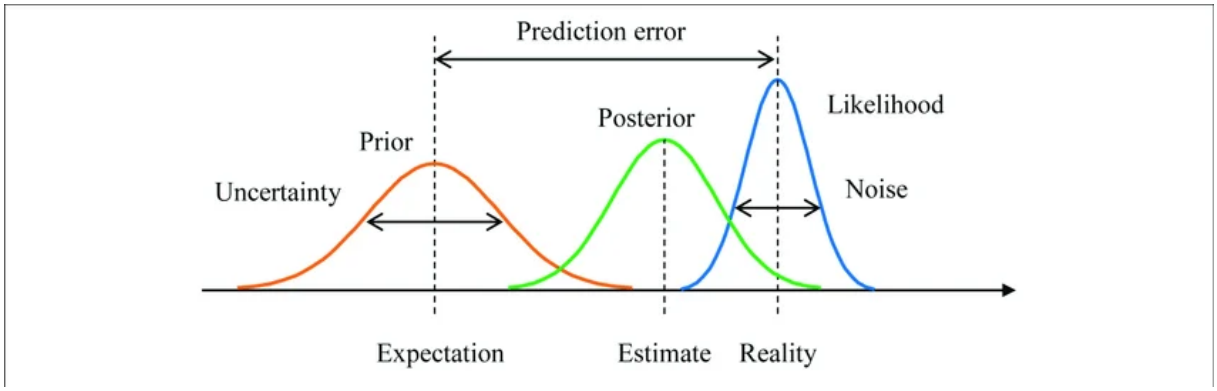

FIGURE 1 – L'équilibre entre connaissances a priori et données observées dans l'inférence bayésienne. *Source : ResearchGate.*

Un point intéressant en pratique, c'est que le terme a priori agit comme une forme de régularisation. Autrement dit, il évite au modèle de "coller" trop parfaitement aux données d'entraînement, ce qui améliore sa capacité à généraliser.

4 Cas pratique : la régression logistique dans un contexte de risque

Les approches probabilistes prennent toute leur importance dès qu'on travaille sur des cas concrets, notamment dans des systèmes critiques comme la finance.

Prenons un exemple simple : la gestion des prêts. Un modèle ne doit pas simplement dire "oui" ou "non". Il doit plutôt estimer un niveau de risque.

4.1 Transformer des données en probabilité

La régression logistique est un bon exemple de modèle probabiliste. À partir d'un vecteur de variables x et de paramètres w, elle calcule une probabilité via la fonction sigmoïde :

$$P(y = 1|x; w) = \frac{1}{1 + e^{-w^T x}}$$

Cette probabilité peut être interprétée comme un score de risque. Plus elle est élevée, plus le profil est considéré comme risqué.

4.2 Le rôle du seuil de décision

Ce qui est intéressant, c'est que la décision finale ne dépend pas directement du modèle, mais d'un seuil τ fixé en fonction du contexte.

— Si $P(y = 1|x; w) > \tau$, on considère que le risque est trop élevé.

— Sinon, l'opération est acceptée.

Ce mécanisme est très utile en pratique. Par exemple, en période d'incertitude économique, il suffit d'ajuster le seuil pour rendre le système plus conservateur, sans avoir à réentraîner tout le modèle.

C'est ce type de compromis entre rigueur mathématique et flexibilité opérationnelle qui rend les approches probabilistes particulièrement adaptées aux systèmes industriels.