

Gouvernance des données à l'ère de l'IA générative : concilier exigences réglementaires et réalité opérationnelle

El Ouali Abderrahman | Ingénieur Data & IA

el-ouali@insa-toulouse.fr

29 juillet 2026

Résumé. La gouvernance des données regroupe l'ensemble des règles, rôles et processus garantissant la qualité, la traçabilité, la sécurité et l'usage responsable des données au sein d'une organisation. L'essor de l'intelligence artificielle générative a profondément renouvelé ces enjeux : les grands modèles de langage introduisent des risques spécifiques – hallucinations, perte de traçabilité, biais hérités des données d'entraînement – qui s'ajoutent aux défis classiques de qualité et de conformité. Cet article propose une synthèse du cadre réglementaire européen (RGPD, règlement sur l'IA), un cadre conceptuel en quatre strates pour structurer la gouvernance, ainsi qu'une discussion illustrée par le cas des secteurs fortement régulés tels que la banque et l'assurance. Il se conclut par des pistes de recherche autour d'une gouvernance des données elle-même assistée par l'IA.

1 Introduction

La donnée est devenue, au cours de la dernière décennie, un actif stratégique pour la quasi-totalité des organisations. Cette évolution s'est accentuée avec l'essor de l'intelligence artificielle générative, qui transforme la manière dont les entreprises collectent, transforment et exploitent leurs données. Les modèles de langage à grande échelle sont désormais intégrés dans des chaînes de décision opérationnelles : systèmes d'aide à la décision, agents conversationnels, outils d'analyse automatisée.

Cette accélération technologique s'accompagne d'un renforcement du cadre réglementaire. Le Règlement Général sur la Protection des Données a posé, dès 2016, les bases d'une gouvernance rigoureuse des données à caractère personnel en Europe [1]. Plus récemment, le règlement européen sur l'intelligence artificielle introduit une approche par les risques, imposant des obligations différenciées selon le niveau de criticité des systèmes d'IA [2]. Ces textes s'inscrivent dans une littérature académique plus large sur la gouvernance des données [3] et sur les cadres éthiques applicables à l'intelligence artificielle [4].

Un écart persiste toutefois entre ces cadres normatifs et leur application concrète. Les équipes data, souvent structurées autour d'impératifs de livraison rapide, peinent à intégrer des pratiques de gou-

vernance perçues comme des freins à l'innovation plutôt que comme des leviers de confiance. Cet article examine cette tension sous un angle à la fois conceptuel et opérationnel, en proposant (i) un cadre en quatre strates pour structurer la gouvernance à l'ère de l'IA générative, (ii) une analyse des risques spécifiques introduits par les grands modèles de langage, et (iii) une discussion illustrée par le cas des secteurs fortement régulés.

2 Cadre réglementaire

Le RGPD reste la pierre angulaire de la protection des données personnelles en Europe. Il impose des principes de minimisation, de limitation des finalités et de transparence [1]. Le règlement européen sur l'IA complète ce dispositif avec une classification des systèmes d'IA en quatre niveaux de risque, illustrée en Figure 1 [2].

Structure par niveaux de risque du règlement européen sur l'IA




Figure 1 : Structure par niveaux de risque du règlement européen sur l'intelligence artificielle. Plus un système d'IA présente un risque pour les droits fondamentaux, plus les exigences de documentation et d'audit sont strictes.

Cette approche graduée traduit une logique de proportionnalité entre le niveau de risque d'un système et l'intensité des obligations qui lui sont imposées.

3 Un cadre conceptuel en quatre strates

Sur la base de cette revue, la gouvernance des données peut se structurer autour de quatre strates complémentaires (Figure 2) : la qualité des données, les métadonnées et la traçabilité, le contrôle des accès, et enfin l'éthique et la conformité réglementaire, qui chapeaute l'ensemble.

Cadre conceptuel en quatre strates pour la gouvernance des données




Figure 2 : Cadre conceptuel en quatre strates pour la gouvernance des données à l'ère de l'IA. Chaque strate dépend de la maturité des strates inférieures.

Une politique éthique robuste (strate 4) est illusoire si les accès ne sont pas maîtrisés (strate 3), qui repose elle-même sur une traçabilité fiable (strate 2), elle-même conditionnée par une qualité de donnée suffisante (strate 1). Cette lecture rejoint les constats sur les défis techniques du *big data*, où la qualité et l'hétérogénéité des sources demeurent des obstacles structurants [5].

4 Risques spécifiques de l'IA générative

L'introduction de grands modèles de langage dans les chaînes de décision fait émerger des risques qui dépassent le cadre traditionnel de la gouvernance des données :

- **Hallucinations** : un modèle génératif peut produire des réponses plausibles mais factuellement erronées, en l'absence de connexion vérifiable à une source de données réelle.
- **Perte de traçabilité** : contrairement à une requête déterministe, une réponse générée est difficilement rejouable à l'identique, ce qui complique l'audit.
- **Biais hérités** : les modèles reproduisent les déséquilibres présents dans leurs données d'entraînement, avec un risque de discrimination indirecte.
- **Dilution des responsabilités** : l'usage de modèles tiers déplace une partie du contrôle hors du périmètre direct de l'organisation.

La Figure 3 propose une représentation conceptuelle – et non une mesure empirique – du compromis observé entre quatre niveaux de gouvernance couramment rencontrés : l'absence de gouvernance formalisée, une gouvernance dite légère, une gouvernance outillée (catalogues, *data contracts*) et une gouvernance *by design*.




Figure 3 : Compromis conceptuel entre vitesse de livraison perçue et niveau de conformité selon le niveau de gouvernance adopté (illustration qualitative).

L'absence de gouvernance procure une vitesse de livraison apparente à court terme, mais expose l'organisation à des risques de conformité et à une dette technique qui se paie ultérieurement, notamment lors des audits réglementaires ou des incidents de qualité de données.

5 Illustration sectorielle

Le secteur bancaire et de l'assurance constitue un terrain d'illustration pertinent pour trois raisons : (i) une réglementation particulièrement dense (RGPD, DSP2, futures obligations liées au règlement sur l'IA) ; (ii) des systèmes d'information reposant souvent sur des architectures historiques co-existant avec des couches modernes de traitement de données ; (iii) une donnée directement liée à des décisions à fort impact pour les clients, ce qui rend les enjeux de gouvernance et d'explicabilité particulièrement sensibles.

Un facteur récurrent de succès dans ce contexte est l'investissement dans la documentation active des données – catalogues, *data contracts*, métadonnées descriptives associées aux transformations – qui réduit significativement le temps de diagnostic en cas d'anomalie [6].

6 Discussion et conclusion

Les cadres réglementaires, bien que nécessaires, restent largement pensés pour des systèmes déterministes ; leur application à des systèmes probabilistes comme les grands modèles de langage soulève

des questions d'interprétation qui ne sont pas encore stabilisées. Par ailleurs, l'outillage technique de la gouvernance progresse plus vite que les processus organisationnels censés l'accompagner.

Une piste émergente consiste à retourner l'intelligence artificielle contre le problème qu'elle contribue à créer : des agents spécialisés pourraient assister la gouvernance elle-même, en détectant automatiquement les dérives de qualité ou en vérifiant la conformité d'un pipeline à des règles métier – une piste qui reste largement prospective.

En résumé, cet article a proposé un cadre en quatre strates pour analyser la gouvernance des données à l'ère de l'IA générative, et souligne une tension persistante entre vitesse d'innovation et exigences de conformité. Les travaux futurs pourraient approfondir cette analyse par une étude de cas empirique, mesurant l'impact concret de différents niveaux de gouvernance sur des indicateurs de qualité, de délai de livraison et de conformité.

Références

- [1] Parlement européen et Conseil de l'Union européenne. *Règlement général sur la protection des données (RGPD)*. Journal officiel de l'Union européenne, 2016.
- [2] Parlement européen et Conseil de l'Union européenne. *Règlement établissant des règles harmonisées concernant l'intelligence artificielle*. Journal officiel de l'Union européenne, 2024.
- [3] V. Khatri, C. V. Brown. Designing data governance. *Communications of the ACM*, 53(1), 148–152, 2010.
- [4] L. Floridi et al. AI4People – An ethical framework for a good AI society. *Minds and Machines*, 28(4), 689–707, 2018.
- [5] H. V. Jagadish et al. Big data and its technical challenges. *Communications of the ACM*, 57(7), 86–94, 2014.
- [6] A. Zaveri et al. Quality assessment for linked data : A survey. *Semantic Web*, 7(1), 63–93, 2016.