

La matrice jacobienne en Deep learning : une synthèse du calcul différentiel à la géométrie

El Ouali Abderrahman | Ingénieur Data & IA
el-ouali@insa-toulouse.fr

July 22, 2026

Résumé. La matrice jacobienne est un outil fondamental du calcul multivarié et l'un des piliers mathématiques du machine learning moderne. Elle rassemble l'ensemble des dérivées partielles d'une fonction vectorielle et caractérise ainsi le comportement linéaire local de cette fonction. En deep learning, la jacobienne régit la manière dont l'information et les gradients se propagent à travers les couches d'un réseau de neurones, constituant le socle mathématique de la rétropropagation. Au-delà de l'entraînement, elle est également un instrument clé pour l'analyse de sensibilité, l'évaluation de la stabilité, et le raisonnement géométrique via les vecteurs tangents et normaux. Cet article passe en revue la définition de la matrice jacobienne, son rôle dans l'optimisation par gradient et la rétropropagation, son interprétation géométrique sur des surfaces paramétrées, ainsi que ses applications en vision par ordinateur, en robotique et en infographie.

1 Introduction

Les systèmes de deep learning modernes sont entraînés en ajustant itérativement des millions de paramètres afin de minimiser une fonction de perte. Ce processus d'optimisation repose entièrement sur la capacité à calculer, à chaque étape, comment de petites variations des entrées d'une fonction se propagent en variations de ses sorties. L'objet mathématique qui formalise cette relation est la **matrice jacobienne**. Comprendre la jacobienne n'est donc pas un exercice périphérique de calcul différentiel, mais un prérequis pour comprendre comment les réseaux de neurones apprennent, comment les gradients sont calculés, et pourquoi certaines architectures sont plus stables ou plus faciles à entraîner que d'autres [1].

2 Définition de la matrice jacobienne

Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ une fonction différentiable à valeurs vectorielles. La matrice jacobienne de f en un point $\mathbf{x}$ regroupe l'ensemble des dérivées partielles du premier ordre :

$$J_f(\mathbf{x}) = \begin{pmatrix} \frac{\partial f_1}{\partial x_1} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1} & \cdots & \frac{\partial f_m}{\partial x_n} \end{pmatrix} \in \mathbb{R}^{m \times n}. \quad (1)$$

Chaque coefficient $J_{ij} = \partial f_i / \partial x_j$ quantifie la sensibilité de la composante de sortie f_i à une petite perturbation de la composante d'entrée x_j . De manière équivalente, $J_f(\mathbf{x})$ est la meilleure approximation linéaire locale de f autour de $\mathbf{x}$: pour un petit déplacement $\delta \mathbf{x}$,

$$f(\mathbf{x} + \delta \mathbf{x}) \approx f(\mathbf{x}) + J_f(\mathbf{x}) \delta \mathbf{x}. \quad (2)$$

La Figure 1 illustre cette idée : une grille régulière

dans l'espace de départ est transformée, sous l'effet d'une fonction non linéaire f , en une grille déformée dans l'espace d'arrivée. Au voisinage d'un point donné, cette déformation est bien approximée par l'application linéaire définie par la jacobienne.




Figure 1: Une grille régulière (à gauche) transformée par une fonction non linéaire f (à droite). La jacobienne au point marqué donne l'approximation linéaire locale de cette déformation.

3 La jacobienne dans les réseaux de neurones

Un réseau de neurones profond peut être vu comme une composition de fonctions couche par couche $f = f_L \circ f_{L-1} \circ \cdots \circ f_1$. La rétropropagation calcule le gradient de la perte par rapport à chaque paramètre en appliquant la règle de la chaîne aux jacobiennes de chaque couche :

$$J_f = J_{f_L} \cdot J_{f_{L-1}} \cdots J_{f_1}. \quad (3)$$

Plutôt que de transmettre une simple valeur scalaire vers l'arrière, chaque couche transmet en réalité une transformation linéaire locale complète, encodée par sa jacobienne, décrivant comment une perturbation en sortie correspond à une perturbation en entrée. C'est ce mécanisme qui permet au gradient de la perte de

se propager vers l'arrière à travers des architectures arbitrairement profondes (Figure 2).




Figure 2: Propagation avant des activations et rétropropagation des gradients, via le produit des jacobienes locales de chaque couche.

Au-delà de l'entraînement, la jacobienne est également centrale pour l'**analyse de sensibilité** et de **stabilité**. Un modèle dont la jacobienne présente de grandes valeurs singulières peut amplifier de petites perturbations en entrée en variations importantes en sortie ; une jacobienne bien conditionnée est en général associée à un paysage d'optimisation plus lisse et à des prédictions plus robustes [2].

4 Interprétation géométrique

La jacobienne se généralise naturellement à la géométrie différentielle. Pour une surface paramétrée par $S(u, v)$, les dérivées partielles $T_u = \partial S / \partial u$ et $T_v = \partial S / \partial v$ définissent les **vecteurs tangents**, qui décrivent comment la surface évolue selon chaque direction du paramétrage. Leur produit vectoriel donne le **vecteur normal** :

$$N = T_u \times T_v, \quad (4)$$

perpendiculaire à la surface en ce point (Figure 3). Cette construction, directement issue de la jacobienne de la paramétrisation S , est largement utilisée en infographie, en robotique et en reconstruction 3D.

Vecteurs tangents et vecteur normal sur une surface




Figure 3: Vecteurs tangents T_u , T_v et vecteur normal $N = T_u \times T_v$ en un point d'une surface paramétrée.

5 Applications

La matrice jacobienne intervient dans un large éventail de domaines appliqués :

- **Vision par ordinateur et reconstruction 3D** : changements de repère, estimation du flux optique, pipelines de structure-from-motion.
- **Robotique** : la jacobienne cinématique relie les vitesses articulaires à la vitesse de l'effecteur, un outil clé pour la planification de mouvement.
- **Infographie** : transformations de coordonnées, calcul des normales pour l'éclairage, animation de surfaces déformables.
- **Deep learning** : rétropropagation, régularisation par jacobienne, réseaux inversibles et normalizing flows [3].

6 Conclusion

Chaque avancée du deep learning repose non seulement sur la donnée et la puissance de calcul, mais aussi sur les structures mathématiques qui rendent l'optimisation possible. La matrice jacobienne, avec l'ensemble plus large des dérivées, des gradients et du calcul vectoriel, fournit le langage formel nécessaire pour décrire comment les réseaux de neurones transforment l'information et comment ils apprennent. Maîtriser ces concepts marque le passage d'une simple utilisation des modèles de machine learning à une compréhension réelle de leur fonctionnement interne — une compétence essentielle pour déboguer, optimiser et fiabiliser les systèmes d'intelligence artificielle.

References

- [1] I. Goodfellow, Y. Bengio, A. Courville. *Deep Learning*. MIT Press, 2016.
- [2] R. Pascanu, T. Mikolov, Y. Bengio. On the difficulty of training recurrent neural networks. *ICML*, 2013.
- [3] D. J. Rezende, S. Mohamed. Variational inference with normalizing flows. *ICML*, 2015.